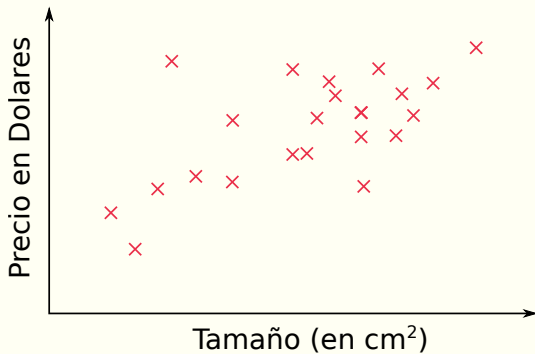



Método del gradiente y regresión lineal

Set de datos para casas I



Set de datos para casas I



Predecir un valor real utilizando los datos disponibles

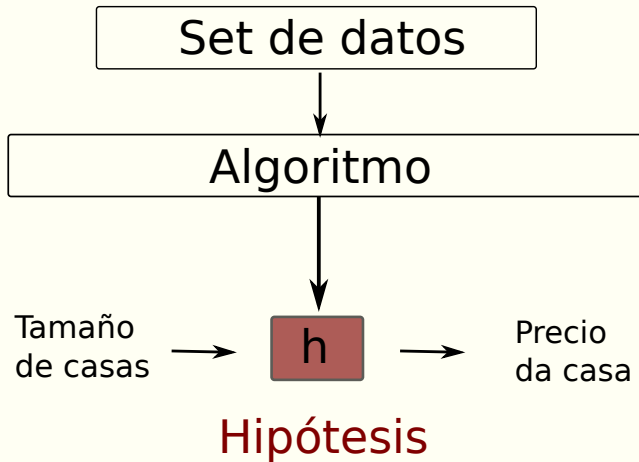
Set de datos para casas II

Tamaño en cm^2	Precio en 1000es de
2014	460
1416	232
1534	178
...	...

Notación:

- \mathbf{m} = Número de puntos de datos
- \mathbf{x} 's = variable de entrada
- \mathbf{y} 's = variable de salida
- $(\mathbf{x}^{(i)}, \mathbf{y}^{(i)})$ = la i -ésima dupla de puntos de data

Hipótesis I



Hipótesis II

Como representamos h ?

Hipótesis II

Como representamos h ?

$$h_{\theta}(x) = \theta_0 + \theta_1 x \quad (1)$$

Regresión lineal de una variable

- ▣ θ_0 y θ_1 son los parámetros del modelo


Hipótesis II

Como representamos h ?

$$h_{\theta}(x) = \theta_0 + \theta_1 x \quad (1)$$

Regresión lineal de una variable

- ▣ θ_0 y θ_1 son los parámetros del modelo



Parámetros θ

¿Como encuentro los parámetros del modelo?

❖ Idea:

- ❖ Elegir θ_0 y θ_1 tal que $h_\theta(x)$ este cercano a los valores y del set de datos (x, y)

Parámetros θ


¿Como encuentro los parámetros del modelo?

❖ Idea:

- ❖ Elegir θ_0 y θ_1 tal que $h_\theta(x)$ este cercano a los valores y del set de datos (x, y)

- ❖ Se debe minimizar $(h_0 - y)^2$ usando θ_0, θ_1 como parametros

$$\min_{\theta_0, \theta_1} \left[\frac{1}{2m} \sum_{i=1}^m ((h_0(x^{(i)}) - y^{(i)})^2 \right] \quad (2)$$



Función de costo

Es conveniente escribir la función a minimizar como una función de costo

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m ((h_0(x^{(i)}) - y^{(i)})^2 \quad (3)$$

$$\min_{\theta_0, \theta_1} J(\theta_0, \theta_1) \quad (4)$$

- ▣ $J(\theta_0, \theta_1)$ = Función de costo, también conocida como función de error cuadrada

Resumen

- ❖ Hipótesis

- ❖ $h_{\theta}(x) = \theta_0 + \theta_1 x$

- ❖ Parametros

- ❖ θ_0, θ_1


- ❖ Función de costo:

- ❖ $J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m ((h_0(x^{(i)}) - y^{(i)})^2$

- ❖ Meta:

- ❖ $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$


Visualizando la función de costo I



Visualizando la función de costo II


$$h_{\theta}(x)$$

(for fixed θ_0, θ_1 , this is a function of x)



$$J(\theta_0, \theta_1)$$

(function of the parameters θ_0, θ_1)



Método del gradiente

Punto de partida

Tenemos una función:

$$J(\theta_0, \theta_1) \quad (5)$$


y queremos minimizarla con respecto a los parámetros θ

$$\min_{\theta_0, \theta_1} J(\theta_0, \theta_1) \quad (6)$$

Estrategia:

- ❖ Elegir θ_0, θ_1 iniciales
- ❖ Cambiar θ_0, θ_1 para reducir $J(\theta_0, \theta_1)$ y llegar a un mínimo.

Descenso a lo largo del gradiente



Algoritmo

Repita hasta convergencia $\{\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)\}$ (Para $j = 0, 1$) (7)

El signo $:=$ significa asignación

α es la tasa de aprendizaje

Se actualiza θ_0 y θ_1 SIMULTANEAMENTE

El gradiente I

Para poder utilizar el algoritmo que se acaba de mostrar es necesario conocer:

$$\frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) \quad (8)$$

Si se calculan las derivadas de J con respecto a θ_0 y θ_1 se obtiene que:

$$\frac{\partial}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_0(x^{(i)}) - y^{(i)}) \quad (9)$$

$$\frac{\partial}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^m (h_0(x^{(i)}) - y^{(i)}) x^{(1)} \quad (10)$$

El gradiente II

Las ecuaciones para poder minimizar la función de costos son entonces:

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_0(x^{(i)}) - y^{(i)}) \quad (11)$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_0(x^{(i)}) - y^{(i)}) x^{(1)} \quad (12)$$

Estos dos cálculos se repiten hasta que J converge a un mínimo.

Vectorización de la ecuaciones

Muchas veces es conveniente escribir las ecuaciones en forma matricial. Por ejemplo la hipótesis:

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 = \theta^T \mathbf{x} \quad (13)$$

$$\mathbf{x} = (x_0, x_1) = (1, x_1) \quad (14)$$